

Informe 1. Evaluación Regresión Lineal

Diplomado en Estadística, mención Métodos Estadísticos

Emilia Barrientos Carrasco

Pablo Campos Abutridy

sábado 1 de agosto de 2026

1. Pregunta 1. Mejor MRLS basado en variables meteorológicas.

Inicialmente, se calculó una matriz de correlaciones entre la variable respuesta y cada una de las variables meteorológicas, con el fin de explorar la intensidad y dirección de sus asociaciones lineales.




Figura 1: Correlaciones entre PM2.5 y las variables meteorológicas.

A partir de este análisis, se observó que la variable PM2.5 presentó correlaciones de mayor magnitud con las variables TMin (-0,63), TProm (-0,62) y Viento (-0,60), las que constituyen variables candidatas para explicar la variabilidad del material particulado.

Luego, se ajustaron modelos de regresión lineal simple utilizando como variable predicha el nivel de PM2.5 y, como predictor, cada una de las variables meteorológicas (Viento, TProm, TMin, TMax y Humed).

Posteriormente, los modelos se compararon considerando principalmente el R^2 y la significancia global del modelo (estadístico F y su valor-p). Se seleccionó aquel con mayor capacidad explicativa, que fue el modelo con el predictor TMin, con un R^2 de 0,3921, el menor error estándar residual (12,87) y el mayor estadístico F (101,9).

Tabla 1: Comparación de MRLS con predictores meteorológicos

	M1		M2		M3		M4		M5	
Predictor		EE		EE		EE		EE		EE
(Intercept)	48.03 ***	2.86	58.00 ***	3.67	45.42 ***	2.47	56.29 ***	5.39	-10.77	6.41
Viento	-26.77 ***	2.82								
TProm			-2.23 ***	0.22						
TMin					-2.51 ***	0.25				
TMax							-1.42 ***	0.22		
Humed									0.54 ***	0.10
Observations	160		160		160		160		160	
R^2 / R^2 adjusted	0.363 / 0.359		0.388 / 0.384		0.392 / 0.388		0.205 / 0.200		0.152 / 0.146	
							* $p < 0.05$	** $p < 0.01$	*** $p < 0.001$	

En seguida, para el modelo seleccionado se verificó el cumplimiento de los supuestos de regresión lineal de manera gráfica y formal.

El supuesto de linealidad se evaluó mediante un gráfico de residuos versus valores ajustados y el test RESET de Ramsey. En el gráfico se observó un patrón en la distribución de los residuos, donde la curva suavizada en lugar de una dispersión aleatoria alrededor de cero, lo que sugiere una posible falta de linealidad. Esta observación fue respaldada por el test RESET ($p < 0,001$), cuyo resultado fue inferior a 0,05, lo que sugiere que existe evidencia de que la forma lineal no describe adecuadamente la relación.

El supuesto de normalidad fue evaluado a partir de un gráfico Q-Q de residuos estandarizados, en el cual se observaron desviaciones persistentes en las colas de la recta, lo que sugiere que el supuesto falla de manera localizada. Formalmente se realizó el test de Shapiro-Wilk que evaluó el supuesto de normalidad de los residuos y a partir del cual se rechazó la hipótesis nula ($W = 0,9649$; $p < 0,001$), existiendo evidencia estadísticamente significativa de que los residuos no siguen una distribución normal.

El supuesto de homocedasticidad fue evaluado gráficamente mediante un gráfico de escala-localización, que permite observar la raíz de los residuos estandarizados, indicando que... Formalmente, el test de Breusch-Pagan indica que existe evidencia estadísticamente significativa de que la varianza de los residuos no es constante ($BP = 41,97$; $p < 0,001$), por lo que existe evidencia de heterocedasticidad.

Adicionalmente, en cuanto a los casos atípicos...





Figura 2: Chequeo de supuestos del MRLS ($\text{PM2.5} \sim \text{TMin}$).


Posterior Predictive Check

Model-predicted lines should resemble observed data line




Linearity

Reference line should be flat and horizontal




Homogeneity of Variance

Reference line should be flat and horizontal



Influential Observations

Points should be inside the contour lines



Normality of Residuals

Q-Qots should fall along the line




Figura 3: Diagnóstico de los supuestos del modelo meteorológico seleccionado.

2. Pregunta 2. Mejor MRLS basado en contaminantes atmosféricos.

2.0.1. Análisis de correlación




Figura 4: Correlaciones entre PM2.5 y los contaminantes.

2.0.2. Modelos con un predictor

2.0.2.1. Predictor: NO

Call:



```
lm(formula = PM2.5 ~ NO, data = df_cont)
```

Residuals:

Min	1Q	Median	3Q	Max
-23.553	-5.536	-1.762	3.866	39.380

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.3279	1.0743	10.54	<2e-16 ***
NO	0.3653	0.0228	16.02	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.19 on 158 degrees of freedom

Multiple R-squared: 0.619, Adjusted R-squared: 0.6166

F-statistic: 256.7 on 1 and 158 DF, p-value: < 2.2e-16

2.0.2.2. Predictor: NO2

Call:

```
lm(formula = PM2.5 ~ NO2, data = df_cont)
```

Residuals:

Min	1Q	Median	3Q	Max
-25.764	-5.436	-0.199	3.146	32.835

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.34591	1.51002	-2.216	0.0281 *
NO2	1.12961	0.05784	19.528	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.933 on 158 degrees of freedom

Multiple R-squared: 0.7071, Adjusted R-squared: 0.7052

F-statistic: 381.4 on 1 and 158 DF, p-value: < 2.2e-16

2.0.2.3. Predictor: CO



Call:

```
lm(formula = PM2.5 ~ CO, data = df_cont)
```

Residuals:

Min	1Q	Median	3Q	Max
-16.701	-5.986	-2.497	4.720	36.102

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.159	1.315	0.881	0.38
CO	27.209	1.399	19.456	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8.957 on 158 degrees of freedom

Multiple R-squared: 0.7055, Adjusted R-squared: 0.7037

F-statistic: 378.5 on 1 and 158 DF, p-value: < 2.2e-16

2.0.2.4. Predictor: O3

Call:

```
lm(formula = PM2.5 ~ O3, data = df_cont)
```

Residuals:

Min	1Q	Median	3Q	Max
-31.923	-7.223	-1.250	5.132	54.387

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	43.7956	2.3922	18.308	<2e-16 ***
O3	-1.1455	0.1173	-9.763	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.03 on 158 degrees of freedom

Multiple R-squared: 0.3763, Adjusted R-squared: 0.3723

F-statistic: 95.32 on 1 and 158 DF, p-value: < 2.2e-16



Characteristic	Beta ¹	SE
<i>O3</i>	-1.1***	0.117

¹*p<0.05; **p<0.01; ***p<0.001

Abbreviations: CI = Confidence Interval, SE = Standard Error

2.1. Chequeo de supuestos del modelo con CO

2.1.1. Linealidad

RESET test

data: mod_cont_co

RESET = 14.133, df1 = 2, df2 = 156, p-value = 2.286e-06

2.1.2. Normalidad

Shapiro-Wilk normality test

data: mod_cont_co\$residuals

W = 0.93716, p-value = 1.649e-06

2.1.3. Homocedasticidad


studentized Breusch-Pagan test

data: mod_cont_co

BP = 11.226, df = 1, p-value = 0.0008067


Posterior Predictive Check

Model-predicted lines should resemble observed data line




Linearity

Reference line should be flat and horizontal




Homogeneity of Variance

Reference line should be flat and horizontal



Influential Observations

Points should be inside the contour lines



Normality of Residuals

Points should fall along the line




Figura 5: Diagnóstico de los supuestos del modelo con CO.




Figura 6: Matriz de correlaciones de todas las variables.



2.1.4. Diagnóstico general

3. Pregunta 3. Mejor modelo predictivo según técnicas iterativas.

3.1. Correlación entre todas las variables

3.2. Selección automática del MRLM

3.2.1. Método backward

Call:

```
lm(formula = PM2.5 ~ Viento + TMin + Humed + NO + NO2 + CO +
    O3, data = df)
```

Residuals:

Min	1Q	Median	3Q	Max
-15.4803	-4.0512	-0.4822	4.4824	23.3433

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-33.5243	6.9520	-4.822	3.41e-06	***
Viento	5.0160	2.3258	2.157	0.032601	*
TMin	-0.7535	0.1992	-3.782	0.000223	***
Humed	0.2983	0.0668	4.465	1.55e-05	***
NO	-0.1343	0.0529	-2.540	0.012090	*
NO2	0.8791	0.1234	7.124	3.92e-11	***
CO	19.8313	2.7794	7.135	3.70e-11	***
O3	0.4343	0.1218	3.565	0.000486	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.988 on 152 degrees of freedom

Multiple R-squared: 0.8276, Adjusted R-squared: 0.8196

F-statistic: 104.2 on 7 and 152 DF, p-value: < 2.2e-16

3.2.2. Método forward

Call:

```
lm(formula = PM2.5 ~ NO2 + CO + Humed + O3 + TMin + NO + Viento,
```



```
data = df)
```

Residuals:

Min	1Q	Median	3Q	Max
-15.4803	-4.0512	-0.4822	4.4824	23.3433

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-33.5243	6.9520	-4.822	3.41e-06 ***
NO2	0.8791	0.1234	7.124	3.92e-11 ***
CO	19.8313	2.7794	7.135	3.70e-11 ***
Humed	0.2983	0.0668	4.465	1.55e-05 ***
O3	0.4343	0.1218	3.565	0.000486 ***
TMin	-0.7535	0.1992	-3.782	0.000223 ***
NO	-0.1343	0.0529	-2.540	0.012090 *
Viento	5.0160	2.3258	2.157	0.032601 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.988 on 152 degrees of freedom

Multiple R-squared: 0.8276, Adjusted R-squared: 0.8196

F-statistic: 104.2 on 7 and 152 DF, p-value: < 2.2e-16

A tibble: 1 x 12

	r.squared	adj.r.squared	sigma	statistic	p.value	df	logLik	AIC	BIC
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	0.828	0.820	6.99	104.	9.73e-55	7	-534.	1086.	1114.

i 3 more variables: deviance <dbl>, df.residual <int>, nobs <int>

3.2.3. Método both

Call:

```
lm(formula = PM2.5 ~ NO2 + CO + Humed + O3 + TMin + NO + Viento,
    data = df)
```

Residuals:

Min	1Q	Median	3Q	Max
-15.4803	-4.0512	-0.4822	4.4824	23.3433

Coefficients:

Estimate	Std. Error	t value	Pr(> t)
----------	------------	---------	----------

```
(Intercept) -33.5243    6.9520   -4.822  3.41e-06 ***
NO2          0.8791     0.1234    7.124  3.92e-11 ***
CO          19.8313     2.7794    7.135  3.70e-11 ***
Humed       0.2983     0.0668    4.465  1.55e-05 ***
O3          0.4343     0.1218    3.565  0.000486 ***
TMin       -0.7535     0.1992   -3.782  0.000223 ***
NO         -0.1343     0.0529   -2.540  0.012090 *
Viento      5.0160     2.3258    2.157  0.032601 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 6.988 on 152 degrees of freedom
Multiple R-squared: 0.8276, Adjusted R-squared: 0.8196
F-statistic: 104.2 on 7 and 152 DF, p-value: < 2.2e-16

3.3. Métricas para seleccionar el mejor modelo

3.3.1. AIC

Tabla 2: AIC de los modelos obtenidos mediante selección automática.

	Backward	Forward	Both
AIC	1085.987	1085.987	1085.987

3.3.2. BIC

Tabla 3: BIC de los modelos obtenidos mediante selección automática.

	Backward	Forward	Both
BIC	1113.664	1113.664	1113.664

Los procedimientos *backward*, *forward* y *both* seleccionaron el mismo modelo final, compuesto por las variables Viento, TMin, Humed, NO, NO2, CO y O3. Aunque las variables aparecen en distinto orden en las fórmulas, el conjunto de predictores es idéntico y, por consiguiente, los modelos son equivalentes. No existe un método superior según las métricas finales: los tres procedimientos convergen a la misma especificación y difieren únicamente en la trayectoria seguida durante la selección.

4. Pregunta 4. Mejor MRLM con tres predictores.

4.1. MRLM con tres predictores

Se selecciona Humed como variable meteorológica y NO2 y CO como contaminantes.

4.1.1. Coeficientes del modelo seleccionado en la pregunta 3

Tabla 4: Coeficientes del modelo seleccionado, ordenados por valor p.

	Estimate	Std. Error	t value	Pr(> t)
Viento	5.0160	2.3258	2.1567	0.0326
NO	-0.1344	0.0529	-2.5400	0.0121
O3	0.4343	0.1218	3.5652	0.0005
TMin	-0.7535	0.1992	-3.7822	0.0002
Humed	0.2983	0.0668	4.4652	0.0000
(Intercept)	-33.5243	6.9520	-4.8223	0.0000
NO2	0.8791	0.1234	7.1243	0.0000
CO	19.8313	2.7794	7.1351	0.0000

4.1.2. Resumen del modelo de tres predictores

Call:

```
lm(formula = PM2.5 ~ Humed + NO2 + CO, data = df)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-19.8915	-3.5512	-0.1145	3.7819	31.2302

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-16.53481	3.29803	-5.014	1.44e-06 ***
Humed	0.23454	0.05310	4.417	1.86e-05 ***
NO2	0.63880	0.09186	6.954	9.18e-11 ***
CO	12.57282	2.26161	5.559	1.15e-07 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 7.58 on 156 degrees of freedom

Multiple R-squared: 0.7918, Adjusted R-squared: 0.7878
F-statistic: 197.7 on 3 and 156 DF, p-value: < 2.2e-16

4.2. Chequeo de supuestos


Posterior Predictive Check

Model-predicted lines should resemble observed data line




Linearity

Reference line should be flat and horizontal




Homogeneity of Variance

Reference line should be flat and horizontal




Influential Observations

Points should be inside the contour lines



Collinearity

High collinearity (VIF) may inflate parameter uncertainty



Normality of Residuals

Points should fall along the line




Figura 7: Diagnóstico general del modelo de tres predictores.

4.2.1. Linealidad

	Test stat	Pr(> Test stat)
Humed	0.5223	0.6022
NO2	0.4106	0.6820
CO	4.6883	5.997e-06 ***
Tukey test	4.1873	2.822e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1




Figura 8: Gráficos de residuos parciales del modelo de tres predictores.

RESET test

data: mod_tres_pred

RESET = 10.598, df1 = 2, df2 = 154, p-value = 4.871e-05

4.2.2. Normalidad



Shapiro-Wilk normality test

```
data: mod_tres_pred$residuals  
W = 0.96995, p-value = 0.001473
```

4.2.3. Homocedasticidad

studentized Breusch-Pagan test

```
data: mod_tres_pred  
BP = 44.069, df = 3, p-value = 1.459e-09
```

4.2.4. Multicolinealidad

Tabla 5: Factores de inflación de la varianza del modelo de tres predictores.

	VIF
Humed	1.100
NO2	3.503
CO	3.652