



Informe 1. Evaluación Regresión Lineal

Diplomado en Estadística, mención Métodos Estadísticos

Emilia Barrientos Carrasco

Pablo Campos Abutridy

domingo 2 de agosto de 2026

1. Pregunta 1. Mejor MRLS basado en variables meteorológicas.

Inicialmente, se calculó una matriz de correlación para cada una de las variables de la base de datos, con el fin de explorar la intensidad y dirección de sus asociaciones lineales (ver Tabla 5). A partir de este análisis, se observó que la variable $PM2.5$ presentó una correlación de mayor magnitud con las variables meteorológicas $TMin$ (-0,63), $TProm$ (-0,62) y $Viento$ (-0,60). Así, se constituyeron como candidatas para explicar la variabilidad del material particulado ($PM2.5$).

Luego, se ajustaron cinco modelos de regresión lineal simple con el objetivo de estimar el nivel de $PM2.5$ a partir de cada uno de los predictores meteorológicos ($Viento$, $TProm$, $TMin$, $TMax$ y $Humed$). Estos modelos se compararon considerando su R^2 y la significancia global de cada uno (estadístico F y su valor-p). Así, se seleccionó el Modelo 3 (predictor $TMin$) porque cuenta con la mayor capacidad explicativa ($R^2 = 0,3921$), el menor error estándar residual (12,87) y el mayor estadístico F (101,9).

Tabla 1: Comparación de MRLS con predictores meteorológicos

	Modelo 1	Modelo 2	Modelo 3	Modelo 4	Modelo 5
(Intercept)	48.033*** (2.865)	58.000*** (3.671)	45.418*** (2.468)	56.285*** (5.389)	-10.774 (6.414)
Viento	-26.767*** (2.822)				
TProm		-2.231*** (0.223)			
TMin			-2.513*** (0.249)		
TMax				-1.417*** (0.222)	
Humed					0.540*** (0.102)
R^2	0.36	0.39	0.39	0.20	0.15
R^2 ajustado	0.36	0.38	0.39	0.20	0.15
Estadístico F	89.98	100.08	101.91	40.69	28.26
Valor-p de F	0.000	0.000	0.000	0.000	0.000
Error estándar residual	13.17	12.91	12.87	14.72	15.20
Observaciones	160	160	160	160	160

En seguida, se verificó el cumplimiento de los supuestos de regresión lineal del Modelo 3 de manera gráfica y formal. En primer lugar, el supuesto de **linealidad** se evaluó mediante un gráfico de residuos

versus valores ajustados (Figura 1) y el test RESET de *Ramsey*. En el gráfico se observó un patrón en la distribución de los residuos de una curva suavizada en lugar de una dispersión aleatoria alrededor de cero, lo que sugiere una posible falta de linealidad. Esta evaluación fue comprobada con el test RESET ($p < 0,001$), cuyo resultado fue inferior a 0,05, lo que sugiere que existe evidencia estadísticamente significativa que la forma lineal no describe adecuadamente la relación.

En segundo lugar, el supuesto de **normalidad** fue evaluado a partir del gráfico Q-Q de residuos estandarizados (Figura 1), en el cual se observaron desviaciones persistentes en las colas de la recta, lo que sugiere que el supuesto falla de manera localizada en los valores extremos. Formalmente se realizó el test de *Shapiro-Wilk* que evaluó el supuesto de normalidad de los residuos y a partir del cual se rechazó la hipótesis nula ($W = 0,9649$; $p < 0,001$), existiendo evidencia estadísticamente significativa de que los residuos no siguen una distribución normal.

En tercer lugar, el supuesto de **homocedasticidad** fue evaluado gráficamente mediante un gráfico de escala-localización (Figura 1), que permite observar la raíz de los residuos estandarizados, indicando que la varianza de los residuos no sigue un patrón constante. Formalmente, el test de *Breusch-Pagan* indica que existe evidencia estadísticamente significativa de que la varianza de los residuos no es constante ($BP = 41,97$; $p < 0,001$), por lo que existe evidencia de heterocedasticidad.

Luego, el supuesto de **independencia** de los residuos fue evaluado formalmente a partir del test de *Durbin-Watson*, obteniendo que no hay evidencia estadísticamente significativa de autocorrelación de los residuos ($p > 0,05$).

Por último, en cuanto a los **casos atípicos**, el gráfico de *leverage* vs. residuos estandarizados (Figura 1) sugiere que no existen observaciones influyentes en la medida en que no parecen existir observaciones que sobrepasen los contornos de distancia de *Cook* (0,5).

2. Pregunta 2. Mejor MRLS basado en contaminantes atmosféricos.

Para estimar este modelo de regresión lineal, primero se observó la matriz de correlación entre la variable *PM2.5* y los cuatro contaminantes atmosféricos (ver Tabla 5). La tabla indicó una fuerte correlación de *PM2.5* con todos los predictores. Sin embargo, fue de mayor magnitud con *NO* y *CO* (0.84).

Luego, se ajustaron cuatro modelos de regresión lineal simple para estimar el nivel de *PM2.5* con cada uno de los contaminantes atmosféricos como variables predictoras. Los modelos 2 (*CO*) y 4 (*NO*) presentaron un ajuste muy similar. Sin embargo, se seleccionó el modelo 4, ya que presentó el mayor coeficiente de determinación ($R^2 = 0,707$) y el menor error estándar residual ($RSE = 8,933$).

Tabla 2: Comparación de MRLS con predictores contaminantes

	Modelo 1	Modelo 2	Modelo 3	Modelo 4
(Intercept)	11.328*** (1.074)	1.159 (1.315)	43.796*** (2.392)	-3.346* (1.510)
NO	0.365*** (0.023)			
CO		27.209*** (1.399)		
O3			-1.145*** (0.117)	
NO2				1.130*** (0.058)
R ²	0.62	0.71	0.38	0.71
R ² ajustado	0.62	0.70	0.37	0.71
Estadístico F	256.69	378.53	95.32	381.36
Valor-p de F	0.000	0.000	0.000	0.000
Error estándar residual	10.19	8.96	13.03	8.93
Observaciones	160	160	160	160

Se verificó el cumplimiento de los supuestos de regresión lineal de manera gráfica y formal. En primer lugar, el supuesto de **linealidad** se evaluó mediante un gráfico de residuos vs. valores ajustados que evidenció una curvatura y un posible incumplimiento del supuesto en la cola superior (ver Figura 2). Formalmente, se estimó el test RESET de *Ramsey*, el que muestra que existe evidencia de que la forma lineal no describe adecuadamente la relación ($p < 0,05$).

En segundo lugar, el supuesto de **normalidad** de los residuos se evaluó visualmente con el gráfico Q-Q de residuos estandarizados. Como se observa en Figura 2, el gráfico evidencia una falla localizada de la normalidad en los extremos, con casos que se separan en las colas. Mediante el test *Shapiro-Wilk* se rechaza H_0 al 5 %, por lo que existe evidencia estadísticamente significativa que los residuos no son normales.

En tercer lugar, se realizó un chequeo de la **homocedasticidad** del modelo mediante un gráfico de escala-localización, donde se observó que la nube de los residuos no es razonablemente estable (ver Figura 2). Formalmente, el test de *Breusch-Pagan* resultó estadísticamente significativo ($BP = 55,17$; $p < 0,001$), por lo que se rechaza la hipótesis nula de homocedasticidad. En consecuencia, existe evidencia de heterocedasticidad, indicando que la varianza de los residuos no es constante a lo largo de los valores ajustados.

Luego, en cuanto al chequeo de independencia, el test de *Durbin-Watson* no evidencia autocorrelación de los residuos ($DW = 2.039$, $p > 0.05$).

Por último, como se observa en Figura 2, el gráfico de observaciones influyentes muestra que la mayoría de las observaciones están concentradas en la zona de bajo *leverage* y residuos cercanos a cero. Además, no parecen existir observaciones que sobrepasen los contornos de distancia de *Cook* (0,5).

3. Pregunta 3. Mejor modelo predictivo según técnicas iterativas.

Para estimar el mejor modelo predictivo de $PM_{2.5}$ según técnicas iterativas, se optó por estimar tres modelos con técnicas *backward*, *forward* y *both*. Las tres seleccionaron el mismo modelo de regresión lineal, compuesto por los predictores *Viento*, *TMin*, *Humed*, *NO*, *NO2*, *CO* y *O3*. Esta equivalencia se observa en la Tabla 3, donde los tres modelos presentan iguales métricas AIC y BIC.

Tabla 3: AIC y BIC de MRLM obtenidos por técnicas de selección iterativas

Criterio	Backward	Forward	Both
AIC	1085.987	1085.987	1085.987
BIC	1113.664	1113.664	1113.664

Dado que las tres técnicas seleccionaron el mismo modelo de regresión lineal, se optó por evaluar el paso a paso del procedimiento de selección *forward*. Como se observa en la Tabla 4, a continuación se describe la variación del R^2 ajustado y del AIC en cada etapa del procedimiento, considerando como referencia el modelo inmediatamente anterior.

El modelo inicial, que incluyó únicamente el intercepto, presentó un R^2 ajustado de 0,000 y un AIC de 1353,215. La incorporación de *NO2* generó la mayor mejora del proceso, elevando el R^2 ajustado a 0,705 (+0,705) y reduciendo el AIC a 1158,769. Posteriormente, la incorporación de *CO* aumentó el R^2 ajustado a 0,763 (+0,058), seguida por *Humed*, que lo elevó a 0,788 (+0,025). Las variables *O3* y *TMin* aportaron incrementos más moderados, alcanzando valores de 0,801 (+0,013) y 0,812 (+0,011), respectivamente. Finalmente, la incorporación de *NO* (+0,003) y *Viento* (+0,005) produjo mejoras marginales, hasta obtener un R^2 ajustado final de 0,820 y el menor AIC entre los modelos comparados (1085,987).

Tabla 4: Comparación de MRLM seleccionados mediante el método forward

	Modelo 1	Modelo 2	Modelo 3	Modelo 4	Modelo 5	Modelo 6	Modelo 7	Modelo 8
(Intercept)	22.719***	-3.346*	-3.112*	-16.535***	-36.076***	-30.249***	-28.699***	-33.524***
NO2		1.130***	0.616***	0.639***	0.704***	0.631***	0.772***	0.879***
CO			14.662***	12.573***	15.151***	15.294***	18.554***	19.831***
Humed				0.235***	0.373***	0.359***	0.314***	0.298***
O3					0.402***	0.510***	0.449***	0.434***
TMin						-0.594**	-0.613**	-0.753***
NO							-0.105*	-0.134*
Viento								5.016*
R^2	0.00	0.71	0.77	0.79	0.81	0.82	0.82	0.83
R^2 ajustado	0.00	0.71	0.76	0.79	0.80	0.81	0.82	0.82
Estadístico F		381.36	256.58	197.72	161.16	137.93	117.98	104.21
Valor-p de F		0.000	0.000	0.000	0.000	0.000	0.000	0.000
Error estándar residual	16.45	8.93	8.01	7.58	7.34	7.14	7.07	6.99
AIC	1353.22	1158.77	1125.01	1108.16	1098.70	1091.09	1088.81	1085.99
Observaciones	160	160	160	160	160	160	160	160

En conjunto, los resultados muestran que la mayor capacidad explicativa se obtuvo con la incorporación de *NO2*, mientras que las variables restantes aportaron mejoras adicionales de menor magnitud, aunque suficientes para alcanzar el mejor desempeño del modelo final.

4. Pregunta 4. Mejor MRLM con tres predictores.

Con base en los resultados obtenidos previamente, se propone un modelo de regresión lineal múltiple para explicar los niveles de *PM2.5*, incorporando como predictores la temperatura mínima (*TMin*), correspondiente a una variable meteorológica, y dos contaminantes atmosféricos: dióxido de nitrógeno (*NO2*) y monóxido de carbono (*CO*). El modelo propuesto se especifica de la siguiente manera:

$$PM_{2.5,i} = \beta_0 + \beta_1 TMin_i + \beta_2 NO_{2,i} + \beta_3 CO_i + \varepsilon_i$$

El modelo de regresión lineal múltiple estimado presentó un R^2 ajustado de 0,77, por lo que el 77,41 % de la variabilidad de la variable dependiente es explicada conjuntamente por los tres predictores. Además, el estadístico F indica que el modelo es estadísticamente significativo ($p < 0,001$). De esta manera, *ceteris paribus*, un aumento de 1°C en $TMin$ se asocia con una disminución esperada de 0,57 unidades de $PM2.5$ ($p < 0,01$), un aumento de 1 ppb de $NO2$ se asocia con un aumento esperado de 0,53 unidades de $PM2.5$ ($p < 0,001$), y un aumento de 1 ppm de CO se asocia con un aumento esperado de 13,70 unidades de $PM2.5$ ($p < 0,001$).

Posteriormente, se verificó el cumplimiento de los supuestos de regresión lineal de manera gráfica y formal. En primer lugar, para chequear el supuesto de **linealidad** se realizó un gráfico de residuos vs. valores ajustados (ver Figura 3). En este se observó una curva suavizada aproximadamente horizontal, aunque con curvaturas en los extremos, lo que podría sugerir un incumplimiento del supuesto. Formalmente, el test RESET de Ramsey resultó estadísticamente significativo (RESET = 3,30; $p < 0,05$), por lo que se rechaza la hipótesis nula. Es decir, existe evidencia de una posible mala especificación de la forma funcional del modelo, por lo que no se cumple adecuadamente el supuesto de linealidad.

En segundo lugar, al evaluar el supuesto de **normalidad** de los residuos, el gráfico Q-Q de residuos estandarizados (Figura 3) muestra que los puntos siguen la línea con desviaciones en las colas superior e inferior, por lo que el supuesto de normalidad podría estar fallando de manera localizada. Por su parte, el test de Shapiro-Wilk resultó estadísticamente significativo ($W = 0,975$; $p < 0,01$), por lo que se rechaza la hipótesis nula de normalidad. En consecuencia, no se cumple el supuesto de normalidad de los residuos.

En tercer lugar, se evaluó el supuesto de **homocedasticidad** revisando que la varianza de los errores permanezca constante a lo largo de todos los valores ajustados. El gráfico de escala-localización (Figura 3) mostró cambios en la dispersión de los residuos en función de los valores ajustados, sugiriendo que su varianza no permanece constante. Esto fue respaldado por el test de Breusch-Pagan, que fue estadísticamente significativo (BP = 53,65; $p < 0,001$), por lo que se rechaza la hipótesis nula de varianza constante. En consecuencia, no se cumple el supuesto de homocedasticidad.

Luego, con respecto al supuesto de **independencia**, el test de Durbin-Watson no evidencia autocorrelación positiva de primer orden en los residuos (DW = 2,17; $p = 0,863$). Asimismo, gráficamente no se identificaron observaciones altamente influyentes (ver Figura 3), aunque algunos casos presentan mayor *leverage* o residuos estandarizados, las observaciones se mantienen dentro de los contornos definidos por la distancia de Cook.

Por último, se evaluó la **multicolinealidad**. La matriz de correlación entre variables predictoras (ver Tabla 5) muestra asociaciones negativas moderadas entre $TMin$ y $NO2$ ($r = -0,61$) y entre $TMin$ y CO ($r = -0,57$). Al mismo tiempo, $NO2$ y CO presentan una alta correlación positiva ($r = 0,84$), lo que evidencia información compartida entre ambos predictores. Este patrón es consistente con el gráfico diagnóstico (Figura 3) basado en el Factor de Inflación de la Varianza (VIF). Los valores obtenidos se encuentran por debajo de 5 para los tres predictores. Como indica formalmente la Tabla 6, $TMin$ presenta el menor VIF (1,616), mientras que CO (3,562) y $NO2$ (3,794) presentan valores más elevados.

En conjunto, estos resultados sugieren una colinealidad baja a moderada entre los predictores, sin alcanzar niveles considerados problemáticos según el criterio $VIF < 5$.

5. Anexos

5.1. Matriz de correlación entre variables

Tabla 5: Matriz de correlación entre variables

	PM2.5	Viento	TProm	TMin	TMax	Humed	NO	NO2	CO	O3
PM2.5	1.00	-0.60	-0.62	-0.63	-0.45	0.39	0.79	0.84	0.84	-0.61
Viento	-0.60	1.00	0.55	0.62	0.38	-0.22	-0.62	-0.71	-0.64	0.53
TProm	-0.62	0.55	1.00	0.90	0.92	-0.67	-0.54	-0.56	-0.56	0.78
TMin	-0.63	0.62	0.90	1.00	0.69	-0.38	-0.59	-0.61	-0.57	0.65
TMax	-0.45	0.38	0.92	0.69	1.00	-0.80	-0.32	-0.34	-0.37	0.74
Humed	0.39	-0.22	-0.67	-0.38	-0.80	1.00	0.19	0.22	0.30	-0.62
NO	0.79	-0.62	-0.54	-0.59	-0.32	0.19	1.00	0.91	0.90	-0.67
NO2	0.84	-0.71	-0.56	-0.61	-0.34	0.22	0.91	1.00	0.84	-0.64
CO	0.84	-0.64	-0.56	-0.57	-0.37	0.30	0.90	0.84	1.00	-0.70
O3	-0.61	0.53	0.78	0.65	0.74	-0.62	-0.67	-0.64	-0.70	1.00


5.2. Tabla VIF del MRLM de tres predictores

Tabla 6: Factor de Inflación de la Varianza (VIF) del MRLM de tres predictores

Predictor	VIF
TMin	1.616
NO2	3.794
CO	3.562


5.3. Diagnóstico de supuestos MRLS con variable meteorológica (PM2.5 ~ Tmin)

Figura 1: Diagnóstico de supuestos del MRLS (PM2.5 ~ TMin)



5.4. Diagnóstico de supuestos MRLS con variable contaminante (PM2.5 ~ CO)

Figura 2: Diagnóstico de supuestos del MRLS (PM2.5 ~ CO)



5.5. Pregunta 4. Diagnóstico de supuestos MRLM con una variable meteorológica y dos contaminantes ($PM_{2.5} \sim TMin + NO_2 + CO$)

Figura 3: Diagnóstico de supuestos del MRLS ($PM_{2.5} \sim TMin + NO_2 + CO$)

